

# Processo Autoregressivo

## UFRGS - FIS01082

Aluno: Henrique Alexandre Boneto - 288744

Maio 2020

### Processos Autoregressivos

Um modelo autorregressivo de ordem  $p$  denotado por  $AR(p)$  é um modelo que tenta prever o futuro baseado em dados passados. É definido como:

$$x_t = c + \sum_{i=1}^p \phi_i x_{t-i} + \epsilon_t$$

Sendo  $\phi_1, \dots, \phi_p$  os parâmetros de ajuste do modelo, e  $\epsilon_t$  é um processo aleatório puro com média zero (ruído branco gaussiano).

### Processos Estacionários

Um processo estacionário é aquele em que suas propriedades não dependem no tempo. Por exemplo, dado uma série de dados, a distribuição de probabilidade dessa série não irá mudar em decorrer do tempo, e por consequência sua média, variância, etc. também não irão mudar.

### Teste da Raiz Unitária

Para que um processo autoregressivo tenha um processo estacionário é preciso que a raiz unitária respeite a seguinte condição para que a variância da série convirja, como demonstrado em aula pelo professor:

$$|a| < 1$$

### Dickey-Fuller

O teste de Dickey-Fuller testa se existe raiz unitária em um modelo autoregressivo. Como também demonstrado pelo professor, o valor de  $\beta$  deve ser menor do que 0 para que a série de dados seja estacionária, já que  $\beta = (a - 1)$ , obtido a partir de uma regressão linear tal que:

$$\Delta X_t = \beta X_{t-1} + \epsilon_t$$

## Equações de Yule-Walker

As equações de Yule-Walker são obtidas a partir do modelo autoregressivo multiplicando as equações pelos atrasos  $X_t, X_{t-1}, \dots, X_{t-p-1}$  e depois aplicando o valor esperado, ficando com:

$$r_p = \sum_{j=1}^p \phi_j r_{p-j}$$

Ou, na forma matricial:

$$\mathbf{R} = \Phi \mathbf{r}$$

Podendo ser resolvida:

$$\Phi = \mathbf{R}^{-1} \mathbf{r}$$

Onde  $\mathbf{R}$  é a matriz de Toeplitz das autocorrelações e  $\Phi$  são os parâmetros a encontrar do modelo.

## Autocorrelação Parcial

A autocorrelação parcial entre duas variáveis é a correlação que sobra caso todas as outras variáveis fossem removidas [2]. Ela será usada pois a função autocorrelação de um modelo autorregressivo se torna zero, mas nunca decaem abruptamente [2].

Por isso, as autocorrelações parciais dão a possibilidade de encontrarmos a ordem de nosso modelo autoregressivo, por exemplo, dado um AR de ordem 2, as autocorrelações parciais para um  $t > 2$  geralmente serão 0 ou muito próximas.

Para um modelo autoregressivo de ordem  $p$  elas são calculadas através da regra de Cramer sobre as equações de Yule-Walker resolvendo para  $\phi_{11}, \phi_{22}, \dots, \phi_{kk}$ .

## Prática

### Série de Dados

Os dados escolhidos para esse trabalho são de um dos índices do mercado financeiro mais famosos do mundo, SP 500 (Standard Poor's 500), entre o período de 2019-01-02 até 2020-01-30, de frequência diária. É composto por quinhentos ativos presentes na bolsa americana (por exemplo Microsoft, Intel, Google...) e é considerado um indicador importante da economia geral dos Estados Unidos. Os dados foram retirados do site Yahoo Finance (<https://finance.yahoo.com>). Abaixo pode-se ver uma amostra dos dados (esses dados são chamados de OHLCV, pois possuem informações da abertura do preço, preço mais alto, baixo e de fechamento, para um período de tempo, assim como a informação de volume financeiro), com a coluna de retornos "returns" já calculada:

	date	open	high	low	close	adj_close	volume	returns
0	2019-01-02	2476.959961	2519.489990	2467.469971	2510.030029	2510.030029	3733160000	0.000000
1	2019-01-03	2491.919922	2493.139893	2443.959961	2447.889893	2447.889893	3822860000	-0.025385
2	2019-01-04	2474.330078	2538.070068	2474.330078	2531.939941	2531.939941	4213410000	0.033196
3	2019-01-07	2535.610107	2566.159912	2524.560059	2549.689941	2549.689941	4104710000	0.006962
4	2019-01-08	2568.110107	2579.820068	2547.560059	2574.409912	2574.409912	4083030000	0.009602
...	...	...	...	...	...	...	...	...
267	2020-01-24	3333.100098	3333.179932	3281.530029	3295.469971	3295.469971	3707130000	-0.009125
268	2020-01-27	3247.159912	3258.850098	3234.500000	3243.629883	3243.629883	3823100000	-0.015982
269	2020-01-28	3255.350098	3285.780029	3253.219971	3276.239990	3276.239990	3526720000	0.009954
270	2020-01-29	3289.459961	3293.469971	3271.889893	3273.399902	3273.399902	3584500000	-0.000868
271	2020-01-30	3256.449951	3285.909912	3242.800049	3283.659912	3283.659912	3787250000	0.003125


272 rows x 8 columns

\*Os retornos financeiros foram calculados com base nos preços de fechamento (coluna "close"), utilizando a seguinte fórmula:

$$r_t = \frac{pc_t - pc_{t-1}}{pc_t}$$

Onde  $r_t$  é o retorno no tempo t,  $pc_t$  é o preço de fechamento no tempo t e  $pc_{t-1}$  é o preço de fechamento no tempo (t-1).

Abaixo o gráfico de retornos gerado:



## Abordagem

Para este trabalho, pretende-se fazer a predição dos retornos financeiros diários do índice ao decorrer do tempo usando um modelo autoregressivo utilizando a linguagem de programação Python. Para isso, primeiramente foram definidos


dois subconjuntos de dados: um para "treinar" (df\_train) o modelo (obter os coeficientes), constituído de um período de 2019-01-02 até 2020-01-28 e outro para "testar" (df\_test) com os resultados obtidos, constituído pelos últimos 3 dias 2020-01-29 até 2020-01-31.

## Estacionariedade

Após isso, para verificar a estacionariedade dos retornos sobre os dados de treino, usou-se o teste da raiz unitária, utilizando uma regressão linear para obter o coeficiente angular da curva. O resultado obtido foi de aproximadamente  $-4.32 \times 10^{-6}$ , concordando com o esperado para um processo estacionário. Além disso, também é possível verificar que a média dos retornos financeiros foi de 0.0009 não mudam com o tempo (sempre muito próximas de zero), assim como sua distribuição de probabilidade tendo comportamento de calda longa.

## PACF

Uma função foi implementada (pode ser vista na seção "Implementação" na função "acf\_pacf"), através das equações de Yule-Walker, para obter as autocorrelações parciais da série de dados para estimar a ordem do modelo a ser utilizada. Os resultados obtidos sobre "df\_train" está abaixo, com as linhas horizontais calculadas como  $\pm 2/\sqrt{N}$  que demonstram um intervalo de confiança de 95% [2](usado para julgar a importância estatística dos coeficientes):




Através do gráfico é possível perceber que somente a primeira ordem de atraso chega mais perto do intervalo de confiança, e os próximos decaem rapidamente.

Desse modo foi escolhido um modelo autoregressivo de ordem 1  $AR(1)$ , entretanto espera-se que os resultados não sejam condizentes com a realidade, visto que é um modelo simples tentando modelar algo complexo como o mercado financeiro. Vale também lembrar que muitas pessoas tomam atitudes dentro do mercado baseados nos acontecimentos do dia anterior,

## Resultados

Abaixo é possível ver os resultados obtidos:



## Implementação

Abaixo o código feito em Python:

```
#author: Henrique Boneto
```

```
#importing libraries
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns
from sklearn.linear_model import LinearRegression
from scipy.linalg import toeplitz
sns.set(style='darkgrid')

#configure data
df = pd.read_csv('data/S&P500.csv')
df.columns = ['date', 'open', 'high', 'low', 'close', 'adj_close', 'volume']
df['returns'] = ((df['close'] - df['close'].shift(1)) / df['close']).fillna(0)
```

```

#define train and test data
df_train = df[df['date'] < '2020-01-28']
df_test = df[df['date'] >= '2020-01-28']

#plotting returns
def plot_returns():
    fig, ax = plt.subplots(figsize=(12,6))
    plt.title('S&P 500 Returns')
    plt.xlabel('Days since 2019-01-02')
    plt.ylabel('Returns')
    ax.plot(df.index, df['returns'])
    plt.savefig('figs/S&P500.png', dpi=300)
plot_returns()

#stationarity
def check_stationarity(df):
    model = LinearRegression()
    x = np.array(df.index).reshape((-1,1))
    y = np.array(df['returns'])
    model.fit(x, y)
    #slope
    print('Slope:', model.coef_)

check_stationarity(df_train)

#implementation of ACF and PACF
def acf_pacf(df, lags=25):
    x = list(df['returns'])
    mean = np.mean(x)
    gama_0 = np.sum((x-mean)**2)
    auto_corr = []

    for i in range(lags+1):
        gama_t = 0
        for t in range(len(x) - i):
            gama_t += ((x[t] - mean) * (x[t+i] - mean)) / gama_0
        auto_corr.append(gama_t)

    R = toeplitz(auto_corr[:len(auto_corr)-1])
    alpha = auto_corr[1:]
    partial_auto_corr = np.linalg.solve(R, alpha)

    return(auto_corr, partial_auto_corr)

acf, pacf = acf_pacf(df_train)

```

```

#implementation of AR
def AR(df, order, n_pred, coefs):
    x = list(df['returns'])
    predictions = []

    for i in range(n_pred):
        pred = np.dot(x[-order:], coefs[:order])
        predictions.append(pred)
        x.append(pred)

    return(predictions)

#plotting PACF
def plot_pacf(df, acf, pacf):
    plt.figure(figsize=(12,6))
    plt.title('PACF')
    plt.xlabel('lag')

    #confidence interval
    y = 2/np.sqrt(df.shape[0])
    plt.axhline(y=y, color='gray', linestyle='--')
    plt.axhline(y=-y, color='gray', linestyle='--')

    #PACF
    plt.bar([0,1], [1,pacf[0]], color='b')
    plt.bar(np.arange(1, len(pacf)+1), pacf, color='b')
    plt.savefig('figs/pacf_S&P500.png', dpi=300)

plot_pacf(df_train, acf, pacf)

#model params choice
n_pred = df_test.shape[0]
order = 1

#make predictions
pred = AR(df_train, order, n_pred, pacf)

#plot results
plt.figure(figsize=(12,6))
plt.title('Results')
plt.xlabel('Days since 2019-01-02')
plt.ylabel('Returns')

plt.plot(df['returns'], label='train')
plt.plot(df_test['returns'], label='test')

```

```
plt.plot(df_test.index, pred, label='predictions', c='black')

plt.xlim([250, 275])
plt.ylim([-0.02, 0.02])
plt.legend()
plt.savefig('figs/ar_results_S&P500.png', dpi=300)
```

## Referências

[1] En.wikipedia.org. 2020. Autoregressive Model. [online] Available at: [https://en.wikipedia.org/wiki/Autoregressive\\_model](https://en.wikipedia.org/wiki/Autoregressive_model) [Accessed 29 May 2020].

[2] Kirchgassner, G. and Wolters, J., 2010. Introduction To Modern Time Series Analysis. Berlin: Springer.

[3] En.wikipedia.org. 2020. S0026p 500 Index. [online] Available at: [https://en.wikipedia.org/wiki/S%26P\\_500\\_Index](https://en.wikipedia.org/wiki/S%26P_500_Index) [Accessed 30 May 2020].

[4] Otexts.com. 2020. 8.1 Stationarity And Differencing — Forecasting: Principles And Practice. [online] Available at: <https://otexts.com/fpp2/stationarity.html> [Accessed 29 May 2020].